Actividad 1 - Arquitecturas con IA

Alumno: German Dario realpe zambrano

Agente de consultas sobre políticas de RRHH de Acme Solutions

Diseño de una solución RAG con LangChain sobre AWS para responder preguntas de empleados utilizando exclusivamente documentos internos autorizados. La propuesta cubre la publicación de políticas, su recuperación y la generación de respuestas con fuentes. Su alcance es arquitectónico; no requiere implementar ni desplegar código.

1 Justificación de la arquitectura seleccionada

Seleccione la Arquitectura de Preguntas y Respuestas sobre Documentos mediante generación aumentada por recuperación (RAG), presentada en el material del curso. El problema exige consultar políticas internas que cambian con el tiempo y responder con evidencia. RAG permite buscar los fragmentos relevantes y entregarlos como contexto a un modelo de lenguaje, sin reentrenarlo cada vez que RRHH actualiza una política.

El agente documental se implementa como un flujo controlado de LangChain: recupera antes de generar. Sus componentes son loaders, splitters, modelo de embeddings, vector store, retriever, plantilla de prompt y modelo generador. La recuperación es obligatoria; el modelo no decide si puede omitirla. En este caso, agente designa al asistente documental, no a un ejecutor autónomo con herramientas abiertas.

Un agente básico con herramientas necesitaría incorporar igualmente la recuperación documental. La memoria conversacional ayuda con el contexto del diálogo, pero no acredita la validez de una política. Las cadenas secuenciales pueden organizar el flujo RAG, mientras que planificación y ejecución añade decisiones y llamadas innecesarias para preguntas frecuentes. Por ello, RAG ofrece una relación adecuada entre precisión, trazabilidad, complejidad y mantenimiento.

La solución cita documento, sección o página y versión. Si la evidencia es insuficiente, ambigua o contradictoria, pide aclaración o deriva a RRHH. RAG reduce las respuestas sin fundamento, pero no garantiza su eliminación: se añaden filtros de autorización y vigencia, comprobación de citas y revisión de soporte documental

2 Diagramas de arquitectura cloud

Las dos figuras representan una única arquitectura. C05 y C06 son recursos compartidos. C04a, C04b y C04c son etapas lógicas de una misma función de consulta. Los actores Empleado y RRHH son personas; no representan servicios AWS. Los controles C12 a C14 se aplican a ambos flujos.



Figura 1. Consulta del empleado. Las flechas numeradas muestran el recorrido; las relaciones de identidad se distinguen por su etiqueta. C04b puede saltar la generación cuando no hay evidencia suficiente.

Recorrido de la consulta

0. **Inicio de sesión.** El empleado accede a la interfaz C01 y se autentica mediante C02.

1. **Envío de la pregunta.** C01 envía la pregunta y el token de acceso a C03.
2. **Validación del acceso.** C03 valida el token e invoca C04. El backend obtiene los grupos del token verificado y aplica sus permisos; no acepta filtros de autorización propuestos por el usuario.
3. **Vectorización de la pregunta.** C04 solicita a C05 el vector que representa la consulta.
4. **Búsqueda documental.** C04 consulta C06 con el vector y los filtros obligatorios de autorización y vigencia.
5. **Recuperación de evidencia.** C06 devuelve los fragmentos autorizados, vigentes y relevantes.
6. **Generación de la respuesta.** Si la evidencia es suficiente, C04 reúne la pregunta, el contexto y los identificadores de fuentes en el prompt y llama a C07. Si falta evidencia, solicita aclaración o remite a RRHH.
7. **Validación del borrador.** C04 comprueba que las citas existan y que las afirmaciones estén respaldadas. Si falta soporte documental, no publica el borrador.
8. **Entrega al empleado.** C04 devuelve la respuesta y sus referencias a C01 a través de C03.

Lectura del diagrama: la flecha C05–C06 representa el paso de datos coordinado por C04; Bedrock no llama directamente a OpenSearch.

El retorno a través de C03 se simplifica en la figura para facilitar la lectura.



Figura 2. Ingesta documental. C09 coordina todas las tareas. Las flechas de texto y vectores representan datos intercambiados por las tareas del flujo; no implican que Bedrock escriba directamente en el índice.

Recorrido y mantenimiento documental

I1–I2. RRHH publíca en C08 documentos aprobados y su manifiesto. C15 recibe el evento y activa C09. I3. Para PDF con texto y DOCX se usan loaders en C11. Para escaneados, C09 inicia el OCR asíncrono de C10, espera y consulta su estado hasta obtener el texto; después invoca C11.

La extracción conserva encabezados, secciones y páginas cuando estén disponibles.

I4–I5. C11 divide el texto por secciones en fragmentos con solapamiento cuando sea necesario. C09 coordina C05 para generar embeddings y C11 para escribir en C06. Se conserva document_id, chunk_id, título, sección o página, versión, fuente, fecha de vigencia, ámbito de aplicación, grupos autorizados y estado de publicación. Tamaño de fragmento, solapamiento y número de resultados se ajustan con preguntas representativas, sin imponer valores arbitrarios.

I6. Antes de publicar se comprueban extracción, metadatos, permisos y número de fragmentos. Cada ejecución se identifica por documento y versión para que repetir un evento no duplique datos; los eventos antiguos no pueden sustituir una versión más reciente. La versión nueva se prepara sin ser visible. Durante el cambio de versión se bloquea temporalmente la recuperación del documento, se desactiva la anterior y se activa la nueva; los lectores verifican también el estado de publicación. Se acepta una breve indisponibilidad antes que mezclar políticas.

Las bajas excluyen inmediatamente el documento cuando se procesan y eliminan sus fragmentos; para una revocación urgente, RRHH bloquea primero el acceso al documento. La retirada de datos del índice no borra automáticamente el historial retenido en S3.

3 Descripción de componentes

Los identificadores coinciden con las figuras. Los componentes de LangChain son software de la aplicación; cada fila identifica el servicio AWS donde se ejecuta o persiste su información.

ID	Componente	Servicio AWS	Rol en la solución	Justificación
C01	Interfaz del empleado	AWS Amplify Hosting	Presenta el chat, envía la consulta autenticada y muestra respuesta, documento, sección y versión.	Aloja una aplicación web con HTTPS y distribución administrada, sin gestionar servidores web.
C02	Identidad corporativa	Amazon Cognito	Federa el inicio de sesión con el proveedor corporativo y emite el token de acceso con los grupos autorizados.	Centraliza autenticación y permite integrar la identidad existente mediante SAML u OIDC. En lugar de que la aplicación tenga su propia base de datos con contraseñas, delega la autenticación en el proveedor de identidad de tu empresa

ID	Componente	Servicio AWS	Rol en la solución	Justificación
C03	Acceso a la API	Amazon API Gateway	Valida el token mediante un autorizador, limita solicitudes y entrega la identidad verificada al backend.	Proporciona una entrada administrada y desacoplada para la función de consulta.
C04	Agente documental y orquestación	AWS Lambda con LangChain	C04a prepara consulta y filtros; C04b recupera y evalúa evidencia y construye el prompt; C04c comprueba citas y devuelve respuesta o abstención.	Ejecuta la lógica bajo demanda. LangChain mantiene explícitos el retriever, el prompt y la llamada al modelo. Las tres etapas pertenecen a una sola función.
C05	Modelo de embeddings	Amazon Bedrock	Transforma fragmentos y preguntas en vectores con el mismo modelo y dimensión; por ejemplo, Titan Text Embeddings V2, sujeto a validación del idioma.	Ofrece inferencia administrada de embeddings y evita mantener un servidor de modelos.
C06	Base documental recuperable	Amazon OpenSearch Serverless	Guarda texto, vectores y metadatos. Recupera fragmentos por similitud con filtros de permisos, ámbito y vigencia aplicados en la consulta.	Combina búsqueda vectorial e índices de texto sin administrar un clúster. Los filtros los impone el backend; el índice no decide los permisos del empleado.
C07	Modelo generador	Amazon Bedrock	Un modelo de texto seleccionado por calidad en español redacta la respuesta a partir del contexto autorizado y referencias suministradas.	Permite consumir modelos de lenguaje mediante una API administrada, sin entrenarlos ni alojarlos.
C08	Repositorio de origen	Amazon S3	Conserva los documentos aprobados, su versión y el manifiesto de permisos y vigencia. RRHH es responsable de publicarlos.	Proporciona almacenamiento durable, versionado y eventos. El historial de S3 no sustituye el control de vigencia del índice.
C09	Coordinación de la ingesta	AWS Step Functions	Coordina extracción, OCR opcional, fragmentación, embeddings y publicación. Espera los trabajos OCR asíncronos con estados de espera y consulta de estado.	Mantiene el estado del procesamiento, los reintentos y los fallos fuera de la función de consulta.

ID	Componente	Servicio AWS	Rol en la solución	Justificación
C10	Lectura de escaneados	Amazon Textract	Extrae texto y estructura de documentos escaneados. C09 inicia el trabajo y consulta su resultado; los archivos con texto nativo omiten este paso.	Reconoce texto en imágenes y PDF, ampliando la cobertura documental del repositorio.
C11	Preparación e indexación	AWS Lambda con LangChain	Ejecuta loaders para texto nativo, normaliza el resultado OCR y divide por secciones; añade fuentes y permisos. C09 la invoca para procesar, validar y publicar en C06.	Separa el tratamiento documental de las consultas y permite cambiar loaders o fragmentación de forma independiente.
C12	Permisos entre servicios	AWS IAM	Asigna roles separados de consulta e ingesta. Restringe acceso a S3, Bedrock, Step Functions y OpenSearch, junto con las políticas del índice.	Aplica privilegio mínimo a las identidades técnicas. Los permisos documentales del empleado se filtran adicionalmente en C04.
C13	Gestión del cifrado	AWS KMS	Gestiona las claves para cifrar S3 y la colección OpenSearch, con acceso limitado a los roles necesarios.	Centraliza el control y la rotación de claves. HTTPS protege por separado los datos en tránsito.
C14	Observabilidad	Amazon CloudWatch	Registra identificadores y versiones consultadas, errores, latencia, consumo y abstenciones, evitando almacenar consultas o documentos completos por defecto.	Reúne métricas, registros y alarmas para detectar fallos y revisar la calidad operativa.
C15	Distribución de eventos	Amazon EventBridge	Recibe los eventos de S3 y activa C09 para altas, cambios y bajas; filtra eventos del repositorio autorizado.	Conecta cambios documentales con el procesamiento asíncrono y desacopla la publicación de la indexación.

4 Seguridad y calidad de las respuestas

Fundamentación y permisos

La búsqueda combina similitud con filtros de grupos autorizados, estado publicado, vigencia y ámbito aplicable. Los filtros se aplican antes de entregar fragmentos al modelo. Cuando el empleado no especifica un país, centro o colectivo necesario para seleccionar la política, se solicita aclaración. La similitud vectorial no demuestra por sí sola que exista evidencia suficiente.

El prompt establece: responder únicamente con el contexto autorizado; no completar políticas con conocimiento general; tratar documentos y preguntas como datos, sin obedecer instrucciones que alteren estas reglas; citar los identificadores suministrados; y reconocer la falta de evidencia. C04 comprueba fuentes y soporte documental con reglas y revisión del borrador frente a los fragmentos, sin tratar otra evaluación del LLM como garantía absoluta. Los casos dudosos se derivan a RRHH. Las referencias se construyen desde metadatos; cualquier enlace al original vuelve a exigir autorización y no expone un bucket público.

Protección y operación

Se usa HTTPS y cifrado en reposo mediante KMS, roles IAM de privilegio mínimo y políticas de acceso a datos de OpenSearch. El navegador solo accede a la interfaz, identidad y API; no recibe credenciales del índice. Los administradores de RRHH gestionan las publicaciones con un rol distinto al del empleado. Se definen retención y acceso a registros; no se almacenan por defecto documentos completos, prompts ni datos personales innecesarios.

La consulta y la ingesta escalan por separado. Lambda limita la concurrencia conforme a las cuotas de Bedrock y del índice; API Gateway limita solicitudes y se usan tiempos de espera acotados. Step Functions gestiona reintentos limitados y estados de error. CloudWatch alerta ante fallos de ingesta, errores de consulta y aumentos de latencia o abstención. Un fallo de recuperación o generación produce un mensaje controlado, nunca una respuesta inventada.

Se versionan prompts, modelos, fragmentación y esquema de metadatos. Cambiar el modelo o la dimensión de embeddings exige crear un índice compatible y reindexar. Se revisan calidad del español, recuperación de fuentes, fidelidad de respuestas, latencia y coste antes de elegir el modelo y la región. OpenSearch Serverless tiene un coste base que debe contrastarse con el volumen previsto. La memoria persistente no es necesaria para este alcance; cualquier historial futuro seguirá sin ser una fuente de políticas.

5 Validación conceptual del diseño

Los siguientes cinco escenarios definen comprobaciones para una futura implementación; no se presentan como pruebas ejecutadas.

1. **Pregunta documentada**: la respuesta coincide con el contenido recuperado y cita documento, sección y versión correctos.

2. **Pregunta sin evidencia:** el agente reconoce la limitación y remite a RRHH.

3. **Pregunta ambigua:** pide el dato necesario antes de seleccionar una política.

4. **Documento restringido:** el contenido no aparece en los fragmentos enviados al modelo ni en la respuesta.

5. **Política sustituida o retirada:** los eventos repetidos no duplican fragmentos y solo se recupera la versión publicada y vigente.

6 Arquitectura técnica AWS

Las versiones técnicas detallan cómo se conectan y protegen los servicios de los diagramas funcionales. Conservan los identificadores C01–C15 y añaden los elementos de red N01–N03 y los controles T01–T03. Cada archivo draw.io contiene dos páginas: Topología AWS y Controles técnicos, con protocolos, permisos y referencias oficiales.

6.1 Consulta del empleado

El navegador obtiene la aplicación desde Amplify, inicia sesión con Cognito y envía la pregunta directamente a API Gateway mediante HTTPS y un token de acceso. El autorizador controla el acceso a la API y AWS WAF protege su stage. API Gateway invoca la función C04 mediante la integración administrada de Lambda.

C04 coordina por separado la inferencia de Bedrock y la búsqueda en OpenSearch Serverless. Su conexión a la VPC utiliza ENI Hyperplane en dos subredes privadas, una en cada zona de disponibilidad. Los endpoints N01 y N02 permiten acceder a los servicios sin publicar la colección ni proporcionar una salida a Internet. La función aplica los filtros documentales, valida la respuesta y la devuelve a través de API Gateway.

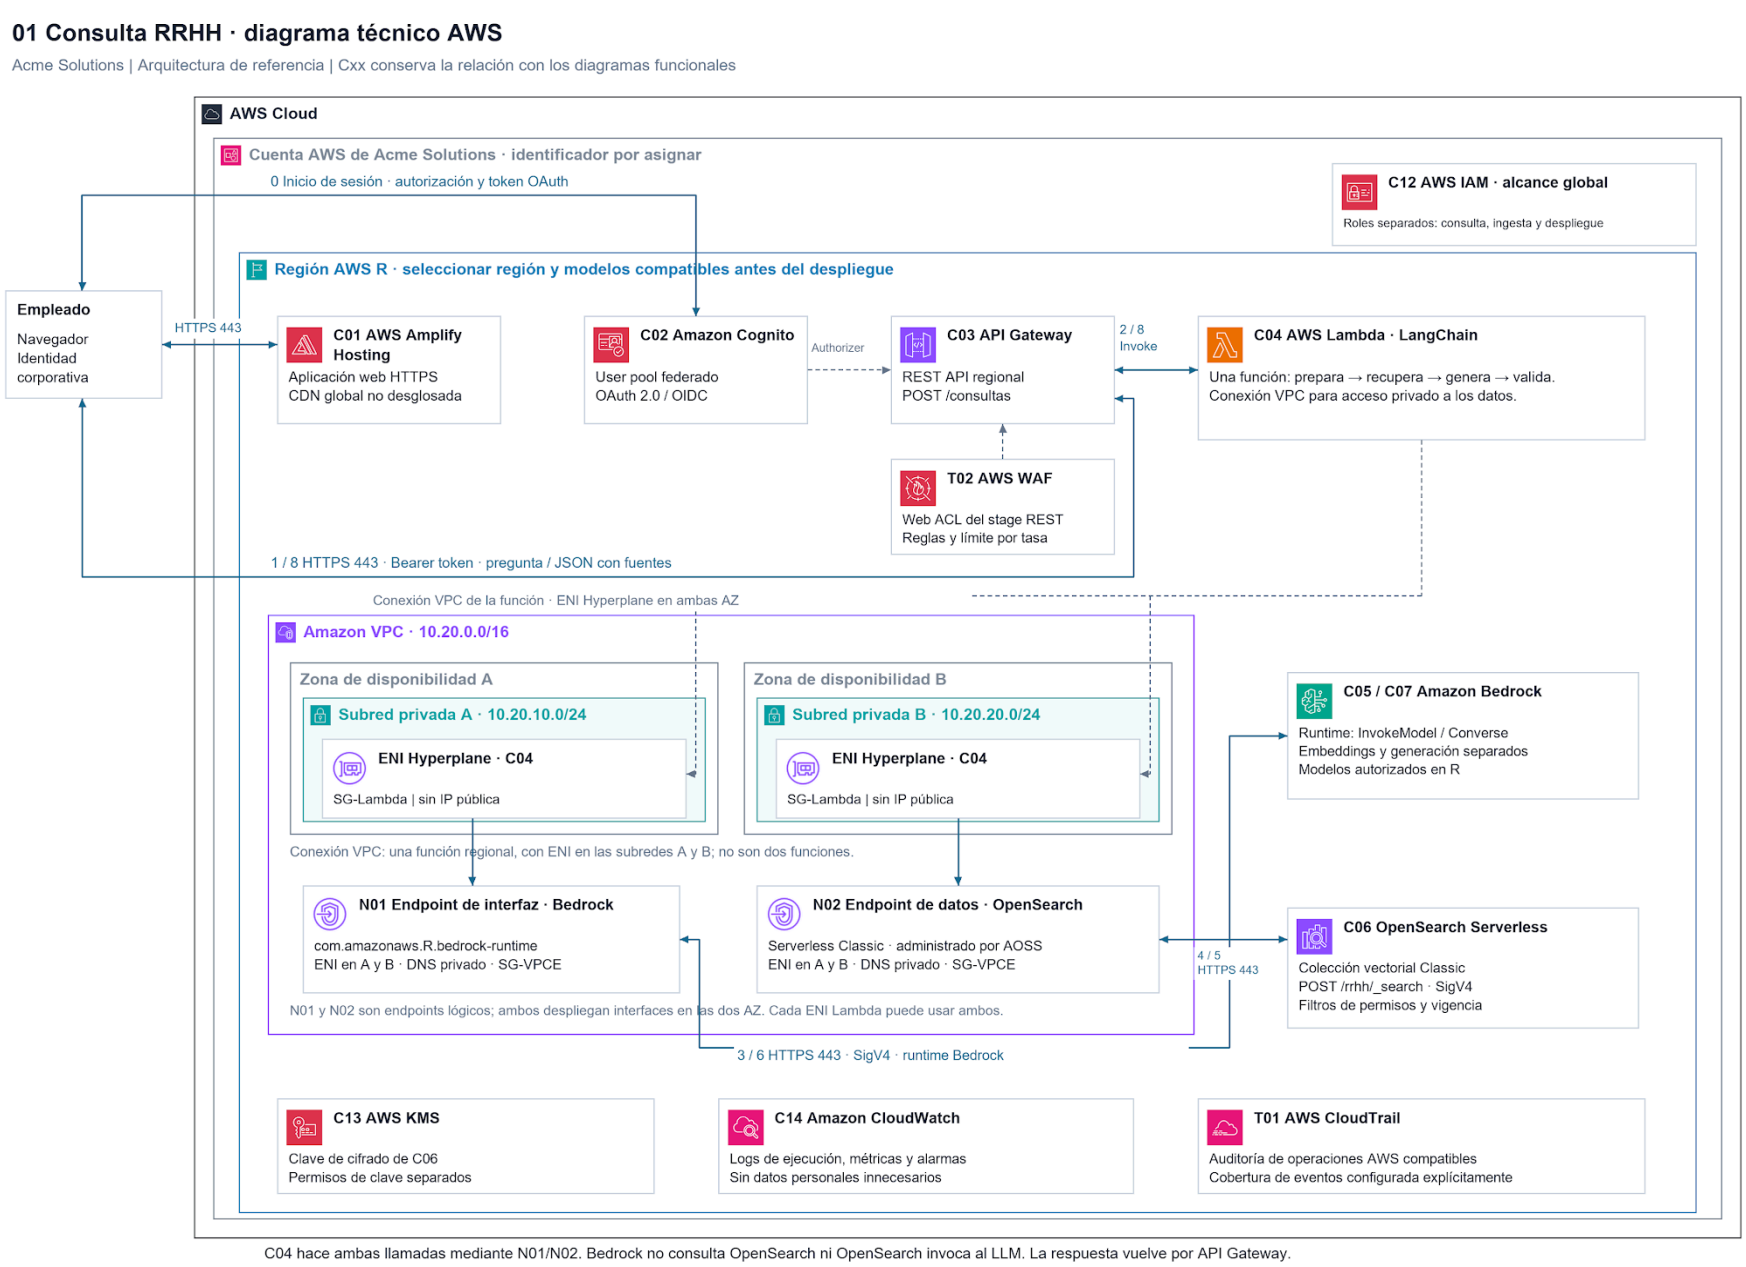


Figura 3. Topología técnica de consulta. Las conexiones continuas representan solicitudes y respuestas; las discontinuas señalan asociaciones o controles. Para consultar los detalles de red, abrir la vista SVG ampliable.

Vista SVG ampliable · Archivo editable draw.io con topología y controles

6.2 Ingesta y actualización documental

RRHH publica documentos aprobados en S3 utilizando un rol autorizado.

EventBridge recibe los eventos y activa un workflow Standard de Step Functions. C09 coordina las tareas de C11 y, cuando el documento está escaneado, inicia y consulta el trabajo asíncrono de Textract.

El procesamiento página los resultados y conserva en el estado referencias a S3, evitando transportar documentos completos entre estados.

C11 prepara fragmentos y metadatos, obtiene sus embeddings mediante N01 y actualiza OpenSearch a través de N02.

Para leer originales o guardar resultados en S3 utiliza el gateway endpoint N03, asociado a las tablas de rutas de las dos subredes.

Las integraciones administradas de Step Functions con Lambda y Textract se realizan desde el servicio AWS; no atraviesan la VPC del cliente.

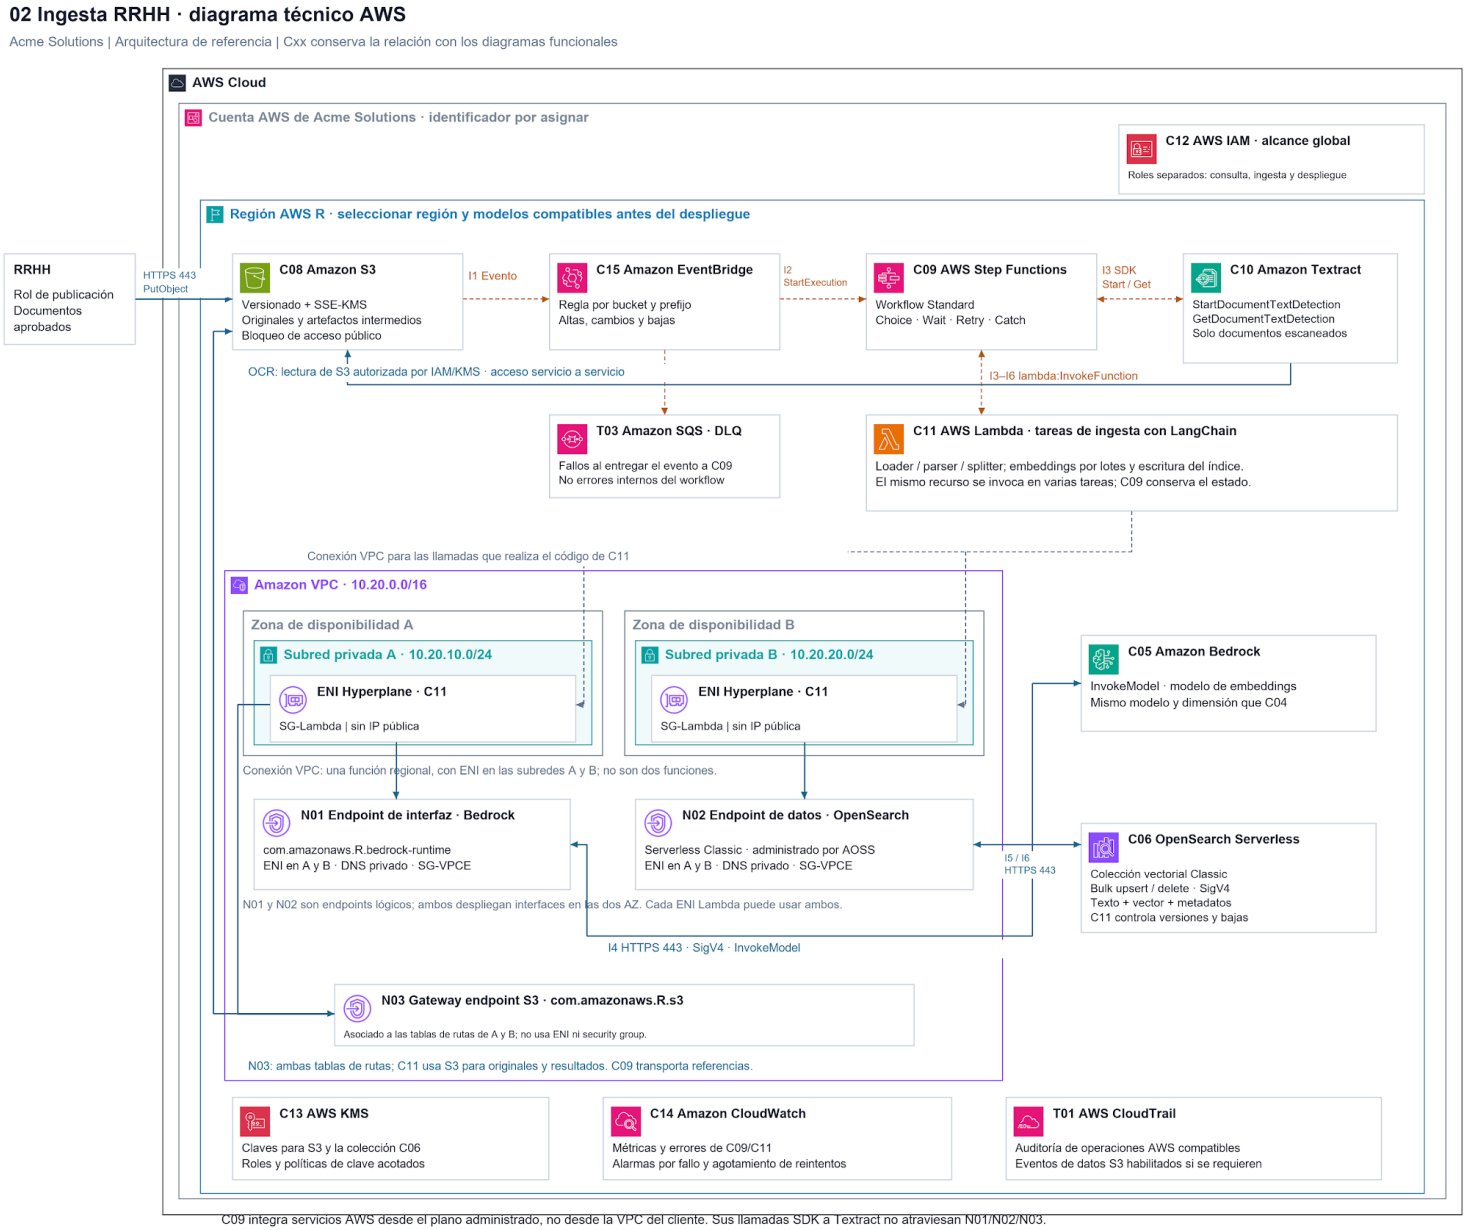


Figura 4. Topología técnica de ingesta. Se distinguen eventos, coordinación del workflow y llamadas privadas de C11. T03 recoge fallos de entrega a C09; los fallos internos del workflow se gestionan por separado.

Vista SVG ampliable · Archivo editable draw.io con topología y controles

6.3 Elementos de red y controles adicionales

- **N01 · Endpoint de interfaz Bedrock.** Permite a C04 y C11 llamar al runtime por HTTPS con firma SigV4. Dispone de interfaces en ambas AZ, DNS privado y una política limitada a principales y modelos autorizados.
- **N02 · Endpoint de datos OpenSearch Serverless.** Proporciona acceso privado a la colección Classic. Se combina con una política de red sin acceso público, permisos IAM sobre la colección y políticas de datos por índice. No debe confundirse con el endpoint de administración de OpenSearch Serverless.
- **N03 · Gateway endpoint S3.** Se utiliza en la ingesta y se asocia a las tablas de rutas de A y B. No utiliza ENI ni security group propios; se controla mediante rutas, endpoint policy y permisos del bucket.
- **T01 · AWS CloudTrail.** Añade auditoría de las operaciones AWS compatibles, con la cobertura de eventos configurada de forma explícita. Complementa las métricas, registros y alarmas de CloudWatch.
- **T02 · AWS WAF.** Añade una Web ACL al stage de la REST API de consulta, con reglas de protección y límites por tasa. El autorizador de Cognito sigue siendo responsable del control de acceso a la API.
- **T03 · Amazon SQS como cola de errores de entrega.** Conserva eventos que EventBridge no logra entregar a C09. La cola es estándar, está en la misma región y permite el envío desde la regla autorizada. Los errores de ejecución de C09 se tratan mediante Retry, Catch y alarmas.

6.4 Seguridad y alcance del diseño

Los roles de consulta e ingesta tienen permisos separados. Los security groups permiten el tráfico necesario hacia los endpoints por TCP 443; para N03 se permite además la prefix list regional de S3. KMS protege los datos en reposo. El acceso a los fragmentos se filtra antes de construir el contexto del modelo y los registros evitan datos personales innecesarios.

La región R, las AZ y los rangos de red representan parámetros del diseño. Antes de desplegar se deben concretar modelos, región, políticas, cuotas y costes, y comprobar el aislamiento y el tratamiento de versiones. Los diagramas se alinean con las convenciones oficiales y las recomendaciones de AWS Well-Architected; no constituyen por sí solos una certificación de cumplimiento.

7 Referencias

Material del curso: Presentación Agentes Langchain 1, página 5, arquitectura RAG; Presentación Agentes Langchain 2, páginas 4–5, ejemplo AWS y claridad de diagramas.

LangChain — Retrieval y arquitecturas RAG

AWS — Búsqueda vectorial en OpenSearch

AWS — Cognito y acceso mediante API Gateway

AWS — Amazon Textract

AWS — Iconos oficiales de arquitectura

AWS — Pilar de seguridad Well-Architected

AWS — Conexión de Lambda a una VPC

AWS — Endpoints privados de Amazon Bedrock

AWS — Acceso privado al plano de datos de OpenSearch Serverless

AWS — Gateway endpoints para S3

AWS — Cola de errores de entrega de EventBridge

Iconografía: paquete oficial AWS de julio de 2026. Se mantienen los archivos originales y su procedencia en diagramas/iconos-aws. El icono oficial de Amazon OpenSearch Service representa el servicio utilizado en modalidad Serverless; los iconos de Lambda y Bedrock se repiten cuando cumplen responsabilidades distintas.